

# Семинары по метрическим методам

Евгений Соколов

11 сентября 2015 г.

## 1 Метод $k$ ближайших соседей

### §1.1 Описание алгоритма

Пусть дана обучающая выборка  $X = (x_i, y_i)_{i=1}^{\ell} \subset \mathbb{X}$  и функция расстояния  $\rho : \mathbb{X} \times \mathbb{X} \rightarrow [0, \infty)$ , и требуется классифицировать новый объект  $u \in \mathbb{X}$ . Расположим объекты обучающей выборки  $X$  в порядке возрастания расстояний до  $u$ :

$$\rho(u, x_u^{(1)}) \leq \rho(u, x_u^{(2)}) \leq \dots \leq \rho(u, x_u^{(\ell)}),$$

где через  $x_u^{(i)}$  обозначается  $i$ -й сосед объекта  $u$ . Алгоритм  *$k$  ближайших соседей* относит объект  $u$  к тому классу, представителей которого окажется больше всего среди  $k$  его ближайших соседей:

$$a(u; X^{\ell}, k) = \arg \max_{y \in Y} \sum_{i=1}^k w_i [y_u^{(i)} = y].$$

Параметр  $k$  обычно настраивается с помощью кросс-валидации.

В классическом методе  $k$  ближайших соседей все объекты имеют единичные веса:  $w_i = 1$ . Такой подход, однако, не является самым разумным. Допустим, что  $k = 3$ ,  $\rho(u, x_u^{(1)}) = 1$ ,  $\rho(u, x_u^{(2)}) = 1.5$ ,  $\rho(u, x_u^{(3)}) = 100$ . Ясно, что третий сосед находится слишком далеко и не должен оказывать сильное влияние на ответ. Эта идея реализуется с помощью весов, обратно пропорциональных расстоянию:

$$w_i = K(\rho(u, x_u^{(i)})),$$

где  $K(x)$  — любая монотонно убывающая функция.

### §1.2 Случай евклидовой метрики

Разберем особенности и проблемы метода  $k$  ближайших соседей, возникающие при использовании евклидовой метрики в качестве функции расстояния:

$$\rho(x, y) = \left( \sum_{i=1}^d |x_i - y_i|^2 \right)^{1/2}.$$

### 1.2.1 Границы классов

Диаграмма Вороного, соответствующая выборке  $X^\ell$  — это такое разбиение пространства на области, что каждая область состоит из точек, для которых одна и та же точка из выборки является ближайшей. Более формально, диаграмма Вороного для выборки  $X^\ell$  состоит из  $\ell$  областей  $R_1, \dots, R_\ell$ , определяемых как

$$R_i = \{x \in \mathbb{R}^d \mid \rho(x, x_i) < \rho(x, x_j), j \neq i\}.$$

Очевидно, что при использовании классификатора ближайшего соседа ( $k = 1$ ) граница между классами является подмножеством границ между такими областями.

**Опр. 1.1.** Область  $R \subset \mathbb{R}^d$  называется *выпуклым многогранником*, если она является пересечением конечного числа полупространств:

$$R = \bigcap_{i=1}^n \{x \in \mathbb{R}^d \mid \langle w_i, x \rangle < 0\}.$$

**Задача 1.1.** Показать, что множество точек, для которых ближайшим соседом из выборки является заданный объект  $x_i$ , представляет собой выпуклый многогранник.

**Решение.** Условие того, что  $x_i$  является ближайшей точкой выборки к  $u$ , записывается как

$$\sum_{p=1}^d (x_{ip} - u_p)^2 < \sum_{p=1}^d (x_{jp} - u_p)^2, \quad j \neq i.$$

Распишем его:

$$\begin{aligned} \sum_{p=1}^d (x_{ip}^2 - 2x_{ip}u_p + u_p^2) &< \sum_{p=1}^d (x_{jp}^2 - 2x_{jp}u_p + u_p^2), \quad j \neq i; \\ \sum_{p=1}^d (x_{ip}^2 - 2x_{ip}u_p) &< \sum_{p=1}^d (x_{jp}^2 - 2x_{jp}u_p), \quad j \neq i; \\ \sum_{p=1}^d (x_{ip}^2 - x_{jp}^2 + 2(x_{jp} - x_{ip})u_p) &< 0, \quad j \neq i; \\ 2 \sum_{p=1}^d (x_{jp} - x_{ip})u_p + \sum_{p=1}^d (x_{ip}^2 - x_{jp}^2) &< 0, \quad j \neq i. \end{aligned}$$

Мы получили набор линейных относительно  $u$  неравенств, каждое из которых задает полупространство. Их пересечение является множеством точек, для которых  $x_i$  является ближайшим соседом, и является выпуклым многогранником по определению. ■

Классификатор одного ближайшего соседа является крайне чувствительным к шумовым объектам и выбросам, и граница между классами может оказаться очень сложной. По мере увеличения  $k$  граница сглаживается за счет «усреднения» по нескольким объектам.

### 1.2.2 Нормализация признаков

Умножим один из признаков (например, первый) на константу  $C$ . Евклидово расстояние примет следующий вид:

$$\rho_2(x, y) = \sqrt{C(x_1 - y_1)^2 + \sum_{i=2}^d (x_i - y_i)^2}.$$

Таким образом, различие по первому признаку будет считаться в  $C$  раз более значимым, чем различия по всем остальным признакам. При этом расположение объектов относительно друг друга не изменилось — изменился лишь масштаб!

Рассмотрим простой пример чувствительности метода ближайшего соседа к масштабу признаков. Допустим, решается задача определения пола человека по двум признакам: росту (в сантиметрах, принимает значения примерно от 150 до 200) и уровню экспрессии гена SRY (безразмерная величина от нуля до единицы; у мужчин ближе к единице, у женщин ближе к нулю). Обучающая выборка состоит из двух объектов:  $x_1 = (180, 0.2)$ , девочка и  $x_2 = (173, 0.9)$ , мальчик. Требуется классифицировать новый объект  $u = (178, 0.85)$ . Воспользуемся классификатором одного ближайшего соседа. Расстояния от  $u$  до объектов обучения равны  $\rho(u, x_1) \approx 2.1$  и  $\rho(u, x_2) \approx 5$ . Мы признаем новый объект девочкой, хотя это не так — высокий уровень экспрессии гена SRY позволяет с уверенностью сказать, что это мальчик. Из-за сильных различий в масштабе признаков уровень экспрессии практически не учитывается при классификации, что совершенно неправильно.

Чтобы избежать подобных проблем, признаки следует нормировать. Это можно делать, например, следующими способами:

- Нормировка на единичную дисперсию:

$$\tilde{x}^j = \frac{x^j - \bar{x}^j}{\sigma(x^j)}.$$

- Нормировка на отрезок  $[0, 1]$ :

$$\tilde{x}^j = \frac{x^j - \min(x^j)}{\max(x^j) - \min(x^j)}.$$

Здесь  $x^j$  — это вектор, составленный из  $j$ -х признаков всех объектов. Иными словами, это  $j$ -й столбец матрицы «объекты-признаки».

### 1.2.3 Шумовые признаки

**Задача 1.2.** Рассмотрим задачу с одним признаком и двумя объектами обучающей выборки:  $x_1 = 0.1$ ,  $x_2 = 0.5$ . Первый объект относится к первому классу, второй — ко второму. Добавим к объектам шумовой признак, распределенный равномерно на отрезке  $[0, 1]$ . Пусть требуется классифицировать новый объект  $u = (0, 0)$ . Какова вероятность, что после добавления шума второй объект окажется к нему ближе, чем первый?

**Решение.** Задача сводится к вычислению вероятности  $\mathbb{P}(0.5^2 + \xi_2^2 \leq 0.1^2 + \xi_1^2)$ , где  $\xi_1$  и  $\xi_2$  — независимые случайные величины, распределенные равномерно на  $[0, 1]$ . Вычислим ее:

$$\begin{aligned} \mathbb{P}(0.5^2 + \xi_2^2 \leq 0.1^2 + \xi_1^2) &= \mathbb{P}(\xi_1^2 \geq 0.24 + \xi_2^2) = \\ &= \int_0^{\sqrt{0.76}} \int_{\sqrt{x_2^2 + 0.24}}^1 dx_1 dx_2 = \int_0^{\sqrt{0.76}} \left(1 - \sqrt{x_2^2 + 0.24}\right) dx_2 \approx 0.275. \end{aligned}$$

■

Таким образом, шумовые признаки могут оказать сильное влияние на метрику. Обнаружить шумовые признаки можно, удаляя поочередно все признаки и смотря на ошибку на тестовой выборке или ошибку кросс-валидации. Более сложные методы отбора информативных признаков будут разобраны позже на лекциях.

#### 1.2.4 «Проклятие размерности»

Пусть объекты выборки — это точки, равномерно распределенные в  $d$ -мерном кубе  $[0, 1]^d$ . Рассмотрим выборку, состоящую из 5000 объектов, и применим алгоритм пяти ближайших соседей для классификации объекта  $u$ , находящегося в начале координат. Выясним, на сколько нужно отступить от этого объекта, чтобы с большой вероятностью встретить пять объектов выборки. Для этого построим подкуб единичного куба, включающий в себя начало координат и имеющий объем  $\delta$ , и найдем такое значение  $\delta$ , при котором в этот подкуб попадет как минимум пять объектов выборки с вероятностью 0.95.

**Задача 1.3.** Запишите выражение для  $\delta$ .

**Решение.**

$$\min \left\{ \delta \mid \sum_{k=5}^{5000} \binom{5000}{k} \delta^k (1 - \delta)^{5000-k} \geq 0.95 \right\}.$$

■

Минимальное значение  $\delta$ , удовлетворяющее этому уравнению, приблизительно равно приблизительно 0.0018. Отсюда находим, что для того, чтобы найти пять соседей объекта  $u$ , нужно по каждой координате отступить на  $0.0018^{1/d}$ . Уже при  $d = 10$  получаем, что нужно отступить на 0.53, при  $d = 100$  — на 0.94. Таким образом, при больших размерностях объекты становятся сильно удалены друг от друга, из-за чего классификация на основе сходства объектов может потерять смысл. В то же время отметим, что в рассмотренном примере признаки объектов представляли собой равномерный шум, тогда как в реальных задачах объекты могут иметь осмысленные распределения, позволяющие построение модели классификации даже при больших размерностях.

Настоящая же проблема, связанная с «проклятием размерности», заключается в невозможности эффективного поиска ближайших соседей для заданной точки. Было показано, что сложность всех популярных методов решения этой задачи становится линейной по размеру выборки по мере роста размерности [1]. В то же время можно добиться эффективного поиска, если решать задачу поиска ближайших

соседей приближенно. Этот вопрос будет разобран более подробно на следующем занятии.

## §1.3 Примеры функций расстояния

### 1.3.1 Метрика Минковского

Метрика Минковского определяется как:

$$\rho_p(x, y) = \left( \sum_{i=1}^d |x_i - y_i|^p \right)^{1/p}$$

для  $p \geq 1$ . При  $p \in (0, 1)$  данная функция метрикой не является, но все равно может использоваться как мера расстояния.

Частными случаями данной метрики являются:

- Евклидова метрика ( $p = 2$ ). Задаёт расстояние как длину прямой, соединяющей заданные точки.
- Манхэттенское расстояние ( $p = 1$ ). Минимальная длина пути из  $x$  в  $y$  при условии, что можно двигаться только параллельно осям координат.
- Метрика Чебышева ( $p = \infty$ ), выбирающая наибольшее из расстояний между векторами по каждой координате:

$$\rho_\infty(x, y) = \max_{i=1, \dots, d} |x_i - y_i|.$$

- «Считающее» расстояние ( $p = 0$ ), равное числу координат, по которым векторы  $x$  и  $y$  различаются:

$$\rho_0(x, y) = \sum_{i=1}^d [x_i \neq y_i].$$

Отметим, что считающее расстояние не является нормой.

Отметим, что по мере увеличения параметра  $p$  метрика слабее штрафует небольшие различия между векторами и сильнее штрафует значительные различия.

В случае, если признаки неравнозначны, используют взвешенное расстояние:

$$\rho_p(x, y; w) = \left( \sum_{i=1}^d w_i |x_i - y_i|^p \right)^{1/p}, \quad w_i \geq 0.$$

**Задача 1.4.** Рассмотрим функцию  $f(x) = \rho_2(x, 0; w)$ . Что представляют из себя линии уровня такой функции?

**Решение.** Распишем квадрат функции  $f(x)$  (форма линий уровня от этого не изменится):

$$f^2(x) = \sum_{i=1}^d w_i x_i^2.$$

Сделаем замену  $x_i = \frac{x'_i}{\sqrt{w_i}}$ :

$$f^2(x') = \sum_{i=1}^d x'^2_i.$$

В новых координатах линии уровня функции расстояния представляют собой окружности с центром в нуле. Сама же замена представляет собой растяжение вдоль каждой из координат, поэтому в исходных координатах линии уровня являются эллипсами, длины полуосей которых пропорциональны  $\sqrt{w_i}$ . ■

Вывод: благодаря весам линии уровня можно сделать эллипсами с осями, параллельными осям координат. Это может быть полезно, если признаки имеют разные масштабы — благодаря весам автоматически будет сделана нормировка.

Веса можно брать, например, равными корреляции между признаком и целевым вектором:

$$w_i = \left| \frac{\sum_{j=1}^{\ell} x_{ji} y_j}{\left(\sum_{j=1}^{\ell} x_{ji}^2\right)^{1/2} \left(\sum_{j=1}^{\ell} y_j^2\right)^{1/2}} \right|.$$

Однако, лучше всего настраивать веса под обучающую выборку с помощью покоординатного спуска или другого метода оптимизации.

### 1.3.2 Расстояние Махаланобиса

Расстояние Махаланобиса определяется следующим образом:

$$\rho(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)},$$

где  $S$  — симметричная положительно определенная матрица.

Напомним, что собственным вектором матрицы  $S$  называется такой вектор  $x$ , что  $Sx = \lambda x$  для некоторого  $\lambda$ . Если матрица  $S$  симметричная, то из ее собственных векторов можно составить ортонормированный базис. Сформировав матрицу  $Q$  из таких собственных векторов (один столбец — один вектор), получим следующие два соотношения:

$$SQ = Q\Lambda \Rightarrow S = Q\Lambda Q^{-1},$$

где  $\Lambda$  — диагональная матрица, в которой записаны собственные значения матрицы  $S$ . При этом матрица  $Q$  является ортогональной:  $Q^T Q = I$ ,  $Q^T = Q^{-1}$ .

Изучим, как ведет себя расстояние Махаланобиса, если с его помощью сравнивать начало координат с произвольной точкой  $x$ . Сделаем для этого замену  $x' = Q^T x$ . Она соответствует такому повороту осей координат, что координатные оси совпадают со столбцами матрицы  $Q$  (то есть с собственными векторами).

Выясним теперь, как выглядят линии уровня метрики в новых координатах:

$$\begin{aligned} \rho^2(x, 0) &= x^T S^{-1} x = x'^T Q^T S^{-1} Q x' = x'^T (Q^{-1} S Q)^{-1} x' = \\ &= x'^T \Lambda^{-1} x' = \sum_{i=1}^d \frac{x'^2_i}{\lambda_i}. \end{aligned}$$

Получаем, что линии уровня представляют собой эллипсы с осями, параллельными осям координат, причем длины полуосей равны корням из собственных значений  $\sqrt{\lambda_i}$ . Таким образом, расстояние Махаланобиса позволяет получить линии уровня в виде произвольно ориентированных эллипсов.

Матрицу  $S$  можно настраивать либо по кросс-валидации, либо брать равной выборочной ковариационной матрице:  $\hat{S} = \frac{1}{n-1} X^T X$ .

**Задача 1.5.** *Покажите, что выборочная ковариационная матрица является неотрицательно определенной.*

**Решение.** Напомним, что матрица  $A$  называется неотрицательно определенной, если  $\langle Az, z \rangle \geq 0$  для всех  $z$ .

Покажем неотрицательную определенность выборочной ковариационной матрицы:

$$\langle X^T X z, z \rangle = (X^T X z)^T z = z^T X^T X z = (X z)^T (X z) = \|X z\|^2 \geq 0.$$

■

### 1.3.3 Косинусная мера

Пусть заданы векторы  $x$  и  $y$ . Известно, что их скалярное произведение и косинус угла  $\theta$  между ними связаны следующим соотношением:

$$\langle x, y \rangle = \|x\| \|y\| \cos(\theta).$$

Соответственно, косинусное расстояние определяется как

$$\rho_{\cos}(x, y) = \arccos \left( \frac{\langle x, y \rangle}{\|x\| \|y\|} \right) = \arccos \left( \frac{\sum_{i=1}^d x_i y_i}{\left( \sum_{i=1}^d x_i^2 \right)^{1/2} \left( \sum_{i=1}^d y_i^2 \right)^{1/2}} \right).$$

Косинусная мера часто используется для измерения схожести между текстами. Каждый документ описывается вектором, каждая компонента которого соответствует слову из словаря. Компонента равна единице, если соответствующее слово встречается в тексте, и нулю в противном случае. Тогда косинус между двумя векторами будет тем больше, чем больше слов встречаются в этих двух документах одновременно.

Один из плюсов косинусной меры состоит в том, что в ней производится нормировка на длины векторов. Благодаря этому она не зависит, например, от размеров сравниваемых текстов, измеряя лишь объем их схожести.

### 1.3.4 Расстояние Джаккарда

Выше мы рассматривали различные функции расстояния для случая, когда объекты обучающей выборки являются вещественными векторами. Если же объектами являются множества (например, каждый объект — это текст, представленный

множеством слов), то их сходство можно измерять с помощью *расстояния Джаккарда*:

$$\rho_J(A, B) = 1 - \frac{|A \cap B|}{|A \cup B|}.$$

**Задача 1.6.** Пусть все множества являются подмножествами некоторого конечного упорядоченного множества  $U = \{u_1, \dots, u_N\}$ . Тогда любое множество  $A$  можно представить в виде бинарного вектора длины  $N$ , в котором единица в  $i$ -й позиции стоит тогда и только тогда, когда  $u_i \in A$ . Запишите формулу для расстояния Джаккарда, исходя из таких обозначений, и сравните ее с формулой для косинусной меры.

**Решение.** Пусть  $X$  и  $Y$  — два множества,  $(x_i)_{i=1}^N$  и  $(y_i)_{i=1}^N$  — их векторные представления. Тогда мощность их пересечения можно записать следующим образом:

$$|X \cap Y| = \sum_{i=1}^N x_i y_i = \langle X, Y \rangle,$$

а мощность их объединения как

$$\begin{aligned} |X \cup Y| &= \sum_{i=1}^N x_i + \sum_{i=1}^N y_i - \sum_{i=1}^N x_i y_i = \\ &= \sum_{i=1}^N x_i^2 + \sum_{i=1}^N y_i^2 - \sum_{i=1}^N x_i y_i = \\ &= \|X\|^2 + \|Y\|^2 - \langle X, Y \rangle. \end{aligned}$$

Тогда:

$$\rho_J(X, Y) = 1 - \frac{\langle X, Y \rangle}{\|X\|^2 + \|Y\|^2 - \langle X, Y \rangle}.$$

■

### 1.3.5 Редакторское расстояние

Для измерения сходства между двумя строками (например, последовательностями ДНК) можно использовать *редакторское расстояние*, которое равно минимальному числу вставок и удалений символов, с помощью которых можно преобразовать первую строку ко второй. В зависимости от специфики задачи можно также разрешать замены, перестановки соседних символов и прочие операции.

### 1.3.6 Функции расстояния на категориальных признаках

Категориальные признаки не имеют никакой явной структуры, и поэтому достаточно сложно ввести на них разумное расстояние. Как правило, ограничиваются сравнением их значений: если у двух объектов одинаковые значения категориального



признака, то расстояние равно нулю, если разные — единице. Тем не менее, существуют определенные соображения по поводу того, как измерять сходство для таких признаков.

Будем считать, что метрика записывается как взвешенная сумма расстояний по отдельным признакам с некоторыми весами:

$$\rho(x, z) = \sum_{j=1}^d w_j \rho_j(x_j, z_j).$$

Способы измерения расстояния для вещественных признаков обсуждались выше. Обсудим некоторые варианты для категориальных признаков. Обозначим через  $f_j(x)$  количество раз, которое  $j$ -й признак принимает значение  $x$  на обучающей выборке; через  $p_j(x) = f_j(x)/\ell$  — частоту категории  $x$ ; через  $p_j^2(x) = f_j(x)(f_j(x) - 1)/(\ell(\ell - 1))$  — оценку вероятности того, что у двух случайно выбранных объектов значения признака будут равны  $x$ .

1. Индикатор совпадения:

$$\rho_j(x_j, z_j) = [x_j \neq z_j]$$

2. Сглаженный индикатор совпадения. Чем выше частота у значения признака, тем больше расстояние (если оба человека живут в Москве, то эта информация не очень важна, поскольку вероятность такого совпадения высока; если оба человека живут в Снежинске, то это важная информация, так событие является достаточно редким):

$$\rho_j(x_j, z_j) = [x_j \neq z_j] + [x_j = z_j] \sum_{q: p_j(q) \leq p_j(x_j)} p_j^2(q)$$

3. Чем более частые значения оказались при несовпадении, тем больше расстояние (если оба человека из разных, но очень маленьких городов, то можно считать их похожими; если один человек из Москвы, а второй — из Питера, то они сильно отличаются):

$$\rho_j(x_j, z_j) = [x_j \neq z_j] \log f_j(x_j) \log f_j(z_j)$$

Более подробный обзор функций расстояния на категориальных признаках можно найти в работе [?].

Существует и другой подход к измерению расстояния между категориальными признаками, основанный на преобразовании их в вещественные. Так, в задачах бинарной классификации крайне эффективной является замена категорий на их условные вероятности получения одного из классов <sup>1</sup>:

$$x_j \rightarrow p(y(x) = 1 \mid f_j(x) = x_j) = \frac{\sum_{i=1}^{\ell} [f_j(x_i) = x_j][y(x_i) = 1]}{\sum_{i=1}^{\ell} [f_j(x_i) = x_j]}$$

---

<sup>1</sup><http://blogs.technet.com/b/machinelearning/archive/2015/02/17/big-learning-made-easy-with-counts.aspx>

## §1.4 Заключение

Основной проблемой метода ближайших соседей является то, что его обучение заключается лишь в запоминании выборки (и, возможно, построении структуры данных для эффективного поиска в ней). При этом не происходит никакой настройки параметров с целью максимизации качества, из-за чего метод не может приспособиться к ненормированным или шумовым признакам. В то же время метод работает с объектами лишь через функцию расстояния, что позволяет использовать его для работы с самыми разнообразными данными (векторами, множествами, строками, распределениями и т.д.).

## Список литературы

- [1] *Weber, R., Schek, H. J., Blott, S.* (1998). A Quantitative Analysis and Performance Study for Similarity-Search Methods in High-Dimensional Spaces. // Proceedings of the 24th VLDB Conference, New York C, 194–205.
- [2] *Boriah, S., Chandola, V., Kumar, V.* (2008). Similarity measures for categorical data: A comparative evaluation. // In Proceedings of the 2008 SIAM International Conference on Data Mining (pp. 243–254).